

# Series de Tiempo

Jonathan Acosta

Magíster en Ciencia de Datos  
Pontificia Universidad Católica de Chile

**Clase en vivo 1**



## 1 Conceptos Fundamentales Semana 1

- Modelos Ingenuos
  - Suavizamientos Exponenciales

## 2 Conceptos Fundamentales Semana 2

- Método de Descomposición
- Funciones de autocorrelación muestrales
  - Test de Blancura

## 1 Conceptos Fundamentales Semana 1

- Modelos Ingenuos
  - Suavizamientos Exponenciales

## 2 Conceptos Fundamentales Semana 2

- Método de Descomposición
- Funciones de autocorrelación muestrales
  - Test de Blancura

¿Qué es una Serie de Tiempo o Serie Cronológica?

¿Qué es una Serie de Tiempo o Serie Cronológica?

Algunos ejemplos:

- Calentamiento Global

¿Qué es una Serie de Tiempo o Serie Cronológica?

Algunos ejemplos:

- Calentamiento Global
- IPC (índice de precio al consumidor)

¿Qué es una Serie de Tiempo o Serie Cronológica?

Algunos ejemplos:

- Calentamiento Global
- IPC (índice de precio al consumidor)
- Indicadores Bursátiles

¿Qué es una Serie de Tiempo o Serie Cronológica?

Algunos ejemplos:


- Calentamiento Global
- IPC (índice de precio al consumidor)
- Indicadores Bursátiles
- Precio del Cobre




# Conceptos Fundamentales Semana 1

**Ejemplo (Calentamiento Global):** Considere el índice de temperatura media mundial entre la tierra y el océano desde 1880 hasta 2015, con el período base 1951-1980.

**Desviaciones de la temperatura global**



# Conceptos Fundamentales Semana 1



# Conceptos Fundamentales Semana 1


**Ejemplo 2 (Promedio Industrial Dow Jones):** Refleja el comportamiento del precio de la acción de las 30 compañías industriales más importantes y representativas de Estados Unidos.



# Conceptos Fundamentales Semana 1


**Obs.:** En las series financieras se suele utilizar y modelizar el retorno:

$$r_t = \frac{x_t - x_{t-1}}{x_{t-1}} \approx \ln(x_t) - \ln(x_{t-1}) = \nabla \ln(x_t)$$



# Introducción

En la siguiente gráfica observamos los datos recogidos en varias localizaciones del cerebro mediante imágenes de resonancia magnética funcional (fMRI).



¿Como identificar la componente periódica, es decir, que valor o valores asignar a la frecuencia  $\omega$ ?

La principal característica de un análisis en series de tiempo es utilizar la información del pasado de la variable para ajustar hacia el futuro.

# Modelos Ingenuos

# Modelos Ingenuos

- Los modelos ingenuos son un conjunto de ecuaciones, que describen una serie de tiempo de forma heurística.
- Existen dos problemas que se pueden abordar usando este tipo de técnica:
  - Obtener una versión suavizada (eliminar ruido).
  - Representación de la serie y predicción.



# Suavizamientos Exponenciales

## Caso Multiplicativo:

## Caso Multiplicativo:

$$\begin{aligned}\overline{X}_t &= \alpha \frac{X_t}{S_{t-p}} + (1 - \alpha) (\overline{X}_{t-1} + m_{t-1}), & \overline{X}_p &= \frac{1}{p} \sum_{i=1}^p X_i \\ m_t &= \beta (\overline{X}_t - \overline{X}_{t-1}) + (1 - \beta) m_{t-1}, & m_p &= 0 \\ S_t &= \gamma \frac{X_t}{\overline{X}_t} + (1 - \gamma) S_{t-p}, & S_j &= \frac{X_j}{\overline{X}_p}, \\ & & j &= 1, \dots, p\end{aligned}$$

## Caso Multiplicativo:

$$\begin{aligned}\overline{X}_t &= \alpha \frac{X_t}{S_{t-p}} + (1 - \alpha) (\overline{X}_{t-1} + m_{t-1}), & \overline{X}_p &= \frac{1}{p} \sum_{i=1}^p X_i \\ m_t &= \beta (\overline{X}_t - \overline{X}_{t-1}) + (1 - \beta) m_{t-1}, & m_p &= 0 \\ S_t &= \gamma \frac{X_t}{\overline{X}_t} + (1 - \gamma) S_{t-p}, & S_j &= \frac{X_j}{\overline{X}_p}, \\ & & j &= 1, \dots, p\end{aligned}$$

Ecuación de pronóstico

$$\hat{X}_t(k) = (\overline{X}_t + m_t k) S_{t-p+k \bmod(p)}$$

## Caso Aditivo:

## Caso Aditivo:

$$\begin{aligned}\bar{X}_t &= \alpha (X_t - S_{t-p}) + (1 - \alpha) (\bar{X}_{t-1} + m_{t-1}), & \bar{X}_p &= \frac{1}{p} \sum_{i=1}^p X_i \\ m_t &= \beta (\bar{X}_t - \bar{X}_{t-1}) + (1 - \beta) m_{t-1}, & m_p &= 0 \\ S_t &= \gamma (X_t - \bar{X}_t) + (1 - \gamma) S_{t-p}, & S_j &= X_j - \bar{X}_p, \\ & & j &= 1, \dots, p\end{aligned}$$

## Caso Aditivo:

$$\begin{aligned}\overline{X}_t &= \alpha (X_t - S_{t-p}) + (1 - \alpha) (\overline{X}_{t-1} + m_{t-1}), & \overline{X}_p &= \frac{1}{p} \sum_{i=1}^p X_i \\ m_t &= \beta (\overline{X}_t - \overline{X}_{t-1}) + (1 - \beta) m_{t-1}, & m_p &= 0 \\ S_t &= \gamma (X_t - \overline{X}_t) + (1 - \gamma) S_{t-p}, & S_j &= X_j - \overline{X}_p, \\ & & j &= 1, \dots, p\end{aligned}$$

Ecuación de Pronóstico:

$$\hat{X}_t(k) = (\overline{X}_t + m_t k) + S_{t-p+k \bmod(p)}$$

## 1 Conceptos Fundamentales Semana 1

- Modelos Ingenuos
- Suavizamientos Exponenciales

## 2 Conceptos Fundamentales Semana 2

- Método de Descomposición
- Funciones de autocorrelación muestrales
- Test de Blancura

## Método de Descomposición



## Método de Descomposición

Estos métodos asumen que una serie se puede descomponer en partes:

## Método de Descomposición

Estos métodos asumen que una serie se puede descomponer en partes:

- Tendencia ( $T_t$ ).

## Método de Descomposición

Estos métodos asumen que una serie se puede descomponer en partes:

- Tendencia ( $T_t$ ).
- Estacionalidad ( $S_t$ ).

## Método de Descomposición

Estos métodos asumen que una serie se puede descomponer en partes:

- Tendencia ( $T_t$ ).
- Estacionalidad ( $S_t$ ).
- Ruido ( $A_t$ ).

Los tres componentes anteriores se pueden relacionar del siguiente modo:

Los tres componentes anteriores se pueden relacionar del siguiente modo:

$$\text{(Modelo Aditivo)} \quad X_t = T_t + S_t + A_t$$

$$\text{(Modelo Multiplicativo)} \quad X_t = T_t \cdot S_t \cdot A_t$$

$$\text{(Modelo Mixto)} \quad X_t = T_t \cdot S_t + A_t$$

Los tres componentes anteriores se pueden relacionar del siguiente modo:

$$(\text{Modelo Aditivo}) \quad X_t = T_t + S_t + A_t$$

$$(\text{Modelo Multiplicativo}) \quad X_t = T_t \cdot S_t \cdot A_t$$

$$(\text{Modelo Mixto}) \quad X_t = T_t \cdot S_t + A_t$$

Las respectivas ecuaciones de pronóstico son:

$$(\text{Modelo Aditivo}) \quad \hat{X}_t(k) = \hat{T}_{t+k} + \hat{S}_{t+k}$$

$$(\text{Modelo Multiplicativo}) \quad \hat{X}_t(k) = \hat{T}_{t+k} \cdot \hat{S}_{t+k}$$

En general para estimar la tendencia podemos utilizar modelos de regresión. Algunos ejemplos:



En general para estimar la tendencia podemos utilizar modelos de regresión. Algunos ejemplos:

❶  $T_t = a + bt$

❷  $T_t = b_0 + b_1t + \dots + b_mt^m$

❸  $T_t = a \cdot e^{bt}$

❹  $T_t = a + b \cdot r^t$  (Exponencial Modificada)

En general para estimar la tendencia podemos utilizar modelos de regresión. Algunos ejemplos:

❶  $T_t = a + bt$

❷  $T_t = b_0 + b_1t + \dots + b_mt^m$

❸  $T_t = a \cdot e^{bt}$

❹  $T_t = a + b \cdot r^t$  (Exponencial Modificada)

Una vez estimada la Tendencia, se procede a calcular la componente Estacional, para ello se define:

Una vez estimada la Tendencia, se procede a calcular la componente Estacional, para ello se define:

$$\text{(Aditivo)} \quad W_t = X_t - \hat{T}_t$$

$$\text{(Mixto)} \quad W_t = \frac{X_t}{\hat{T}_t}$$

Una vez estimada la Tendencia, se procede a calcular la componente Estacional, para ello se define:

$$\text{(Aditivo)} \quad W_t = X_t - \hat{T}_t$$

$$\text{(Mixto)} \quad W_t = \frac{X_t}{\hat{T}_t}$$

Si el periodo de la serie es  $P$ , ejemplo  $P = 12$ , se tiene

$$S_t = S_{t+12} = S_{t+24} = \cdot = S_{t+k12}$$

Así que basta estimas  $S_t$  para  $t = 1, \dots, P$ , ejemplo  $P = 12$ .

Se definen

$e(h)$  : Promedio de los valores de  $W$  en el mes  $h$ .

$$\bar{e} = \frac{1}{P} \sum_{h=1}^P e(h)$$

Luego,

Se definen

$e(h)$  : Promedio de los valores de  $W$  en el mes  $h$ .

$$\bar{e} = \frac{1}{P} \sum_{h=1}^P e(h)$$

Luego,

$$\text{(Aditivo)} \quad \hat{S}_h = e(h) - \bar{e}$$


$$\text{(Multiplicativo)} \quad \hat{S}_h = e(h) - (\bar{e} - 1)$$

# Filtros de Media Móvil



# Modelos Ingenuos

Al aplicar filtros de media móvil a la base de temperatura global, se obtiene:



¿Para que sirven las funciones de autocorrelación muestrales?

## Proposición (Test de Box-Pierce-Ljung)

Considere las hipótesis

- $H_0$ : Los residuos no son correlacionados.
- $H_1$ : Los residuos tienen correlación.

Para poner a prueba las hipótesis anterior, se define el estadístico:

$$Q = n(n+2) \sum_{h=1}^H \frac{\hat{\rho}_e^2(h)}{n-h} \xrightarrow[H_0]{D} \chi_{H-p-q}^2$$

Por lo tanto, se rechaza  $H_0$  con significancia  $\alpha$  % si  $Q > \chi_{H-p-q, 1-\alpha}^2$ .

## Proposición (Test de Box-Pierce-Ljung)

Considere las hipótesis

- $H_0$ : Los residuos no son correlacionados.
- $H_1$ : Los residuos tienen correlación.

Para poner a prueba las hipótesis anterior, se define el estadístico:

$$Q = n(n+2) \sum_{h=1}^H \frac{\hat{\rho}_e^2(h)}{n-h} \xrightarrow[H_0]{D} \chi_{H-p-q}^2$$

Por lo tanto, se rechaza  $H_0$  con significancia  $\alpha$  % si  $Q > \chi_{H-p-q, 1-\alpha}^2$ .

**Obs.:** Típicamente,  $H = 20$  o  $H = \frac{n}{4}$ .

¿Alguna Consulta?