



**UC** | Chile



**UC** | Chile

## **Algebra Lineal Aplicada para Ciencia de Datos**



# Clase 8. Descomposición en valores singulares




- 1 Introducción
- 2 Tema 1: Descomposición en valores singulares
- 3 Tema 2: Teorema de Eckart-Young
- 4 Tema 3: Análisis de Componentes principales



**UC** | Chile

# Introducción

# Introducción y motivación



- La descomposición en valores singulares (SVD) y el análisis de componentes principales (PCA) son herramientas esenciales en álgebra lineal y análisis de datos.
- Ambos tienen aplicaciones extensas en diversas áreas, incluyendo procesamiento de imágenes, aprendizaje automático, estadísticas y más.
- Comprender estos conceptos nos permite entender la estructura subyacente y reducir la dimensionalidad de los datos.

## Objetivos de la clase

- Introducir la descomposición en valores singulares (SVD) como una herramienta fundamental en álgebra lineal.
- Explorar el análisis de componentes principales (PCA) y su aplicación en la reducción de la dimensionalidad.



**UC** | Chile

# **Tema 1: Descomposición en valores singulares**

# Introducción a la SVD



La **descomposición en valores singulares** (SVD) es una factorización matricial importante. Dada una matriz  $A$ , se puede expresar como:

$$A = U\Sigma V^T$$

donde:

- ▣  $U$  y  $V$  son matrices ortogonales.
- ▣  $\Sigma$  es una matriz diagonal con los valores singulares.

## Teorema



Sea  $A \in \mathbb{R}^{m \times n}$ . Entonces, existen matrices ortogonales

$$U = \begin{bmatrix} u_1 & \cdots & u_m \end{bmatrix} \in \mathbb{R}^{m \times m} \quad \text{y} \quad V = \begin{bmatrix} v_1 & \cdots & v_n \end{bmatrix} \in \mathbb{R}^{n \times n}$$

tales que

$$U^{\top} A V = \Sigma = \text{diag}(\sigma_1, \dots, \sigma_p) \in \mathbb{R}^{m \times n}, \quad p = \min\{m, n\}$$

y con  $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_p \geq 0$ .



## Corolario



Los escalares  $\sigma_i$ ,  $1 \leq i \leq p$  son los **valores singulares**, los vectores  $u_i$ ,  $1 \leq i \leq m$  son los **vectores singulares izquierdos**, los vectores  $v_i$ ,  $1 \leq i \leq n$  son los **vectores singulares derechos**.

$$A = U\Sigma V^T$$

- Si  $m \geq n$  se tiene que:  $Av_i = \sigma_i u_i$  y  $A^T u_i = \sigma_i v_i$ , para  $1 \leq i \leq n$ .
- Si  $m \leq n$  se tiene que:  $Av_i = \sigma_i u_i$  y  $A^T u_i = \sigma_i v_i$ , para  $1 \leq i \leq m$ .

## Corolario

Los escalares  $\sigma_i$ ,  $1 \leq i \leq p$  son los **valores singulares**, los vectores  $u_i$ ,  $1 \leq i \leq m$  son los **vectores singulares izquierdos**, los vectores  $v_i$ ,  $1 \leq i \leq n$  son los **vectores singulares derechos**.

$$A = \begin{bmatrix} | & \cdots & | \\ u_1 & \cdots & u_m \\ | & \cdots & | \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sigma_n \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} | & \cdots & | \\ v_1 & \cdots & v_n \\ | & \cdots & | \end{bmatrix}^{\top}, \quad m \geq n$$

- Si  $m \geq n$  se tiene que:  $Av_i = \sigma_i u_i$  y  $A^{\top} u_i = \sigma_i v_i$ , para  $1 \leq i \leq n$ .
- Si  $m \leq n$  se tiene que:  $Av_i = \sigma_i u_i$  y  $A^{\top} u_i = \sigma_i v_i$ , para  $1 \leq i \leq m$ .

## Corolario

Los escalares  $\sigma_i$ ,  $1 \leq i \leq p$  son los **valores singulares**, los vectores  $u_i$ ,  $1 \leq i \leq m$  son los **vectores singulares izquierdos**, los vectores  $v_i$ ,  $1 \leq i \leq n$  son los **vectores singulares derechos**.

$$A = \begin{bmatrix} | & \cdots & | \\ u_1 & \cdots & u_m \\ | & \cdots & | \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sigma_n \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \text{---} & v_1 & \text{---} \\ \vdots & \vdots & \vdots \\ \text{---} & v_n & \text{---} \end{bmatrix}, \quad m \geq n$$

- Si  $m \geq n$  se tiene que:  $Av_i = \sigma_i u_i$  y  $A^\top u_i = \sigma_i v_i$ , para  $1 \leq i \leq n$ .
- Si  $m \leq n$  se tiene que:  $Av_i = \sigma_i u_i$  y  $A^\top u_i = \sigma_i v_i$ , para  $1 \leq i \leq m$ .

## Corolario

Los escalares  $\sigma_i$ ,  $1 \leq i \leq p$  son los **valores singulares**, los vectores  $u_i$ ,  $1 \leq i \leq m$  son los **vectores singulares izquierdos**, los vectores  $v_i$ ,  $1 \leq i \leq n$  son los **vectores singulares derechos**.

$$A = \begin{bmatrix} | & \cdots & | \\ u_1 & \cdots & u_m \\ | & \cdots & | \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & 0 & 0 \\ 0 & \ddots & 0 & 0 \\ 0 & 0 & \sigma_n & 0 \end{bmatrix} \begin{bmatrix} \text{---} & v_1 & \text{---} \\ \vdots & \vdots & \vdots \\ \text{---} & v_n & \text{---} \end{bmatrix}, \quad m \leq n$$

- Si  $m \geq n$  se tiene que:  $Av_i = \sigma_i u_i$  y  $A^\top u_i = \sigma_i v_i$ , para  $1 \leq i \leq n$ .
- Si  $m \leq n$  se tiene que:  $Av_i = \sigma_i u_i$  y  $A^\top u_i = \sigma_i v_i$ , para  $1 \leq i \leq m$ .

# Descomposición en Valores Singulares



Dada la matriz  $A = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$ , queremos calcular su descomposición en valores singulares

$$A = U\Sigma V^T$$

## Estrategia del cálculo



- Calcular  $AA^T$  y  $A^T A$ .
- Calcular valores y vectores propios de  $AA^T \rightarrow \lambda_i, u_i$ .
- Calcular valores y vectores propios de  $A^T A \rightarrow \lambda_i, v_i$ .
- Valores singulares  $\sigma_i = \sqrt{\lambda_i}$ .

## Cálculo de $A^T A$ y $AA^T$

Primero, calculemos  $A^T A$  y  $AA^T$ :

$$AA^T = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix} \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}^T = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix} \begin{bmatrix} 3 & 4 \\ 0 & 5 \end{bmatrix} = \begin{bmatrix} 9 & 12 \\ 12 & 41 \end{bmatrix}$$

$$A^T A = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}^T \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix} = \begin{bmatrix} 3 & 4 \\ 0 & 5 \end{bmatrix} \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix} = \begin{bmatrix} 25 & 12 \\ 12 & 25 \end{bmatrix}$$

## Cálculo de valores y vectores propios de $AA^\top$

$$\det(AA^\top - \lambda I) = 0 \implies (9 - \lambda)(41 - \lambda) - 12^2 = 0 \implies \lambda_1 = 45, \lambda_2 = 5$$

$$(AA^\top - \lambda_1 I)u_1 \implies \begin{bmatrix} 9 - 45 & 12 \\ 12 & 41 - 45 \end{bmatrix} u_1 = 0 \implies u_1 = \frac{1}{\sqrt{10}} \begin{bmatrix} 1 \\ 3 \end{bmatrix}$$

$$(AA^\top - \lambda_2 I)u_2 \implies \begin{bmatrix} 9 - 5 & 12 \\ 12 & 41 - 5 \end{bmatrix} u_2 = 0 \implies u_2 = \frac{1}{\sqrt{10}} \begin{bmatrix} -3 \\ 1 \end{bmatrix}$$

$$\text{Así } U = [u_1, u_2].$$



## Cálculo de valores y vectores propios de $AA^\top$

$$\det(A^\top A - \lambda I) = 0 \implies (25 - \lambda)(25 - \lambda) - 12^2 = 0 \implies \lambda_1 = 45, \lambda_2 = 5$$

$$(A^\top A - \lambda_1 I)v_1 \implies \begin{bmatrix} 25 - 45 & 12 \\ 12 & 25 - 45 \end{bmatrix} v_1 = 0 \implies v_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$(A^\top A - \lambda_2 I)v_2 \implies \begin{bmatrix} 25 - 5 & 12 \\ 12 & 25 - 5 \end{bmatrix} v_2 = 0 \implies v_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$\text{Así } V = \begin{bmatrix} v_1 & v_2 \end{bmatrix}.$$

# Construcción de la Descomposición en Valores Singulares


Finalmente, obtenemos los valores singulares

$$\sigma_1 = \sqrt{\lambda_1} = \sqrt{45}, \quad \sigma_2 = \sqrt{\lambda_2} = \sqrt{5},$$

y construimos la descomposición en valores singulares  $A = U\Sigma V^T$ :

$$\underbrace{\begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}}_A = \underbrace{\frac{1}{\sqrt{10}} \begin{bmatrix} 1 & -3 \\ 3 & 1 \end{bmatrix}}_U \underbrace{\begin{bmatrix} \sqrt{45} & 0 \\ 0 & \sqrt{5} \end{bmatrix}}_\Sigma \underbrace{\frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}^T}_{V^T}$$

# Interpretación geométrica





**UC** | Chile

## **Tema 2: Teorema de Eckart-Young**

## Observación

Descomposición de  $A$  en matrices de rango 1.

$$A = \begin{bmatrix} | & | & & | & \cdots & | \\ u_1 & u_2 & \cdots & u_n & \cdots & u_m \\ | & | & & | & & | \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \sigma_n \\ 0 & \cdots & 0 & 0 \end{bmatrix} \begin{bmatrix} \text{---} & v_1 & \text{---} \\ \text{---} & v_2 & \text{---} \\ \vdots & \vdots & \vdots \\ \text{---} & v_n & \text{---} \end{bmatrix}$$

=

## Observación

Descomposición de  $A$  en matrices de rango 1.

$$A = \begin{bmatrix} | & | & & | & \cdots & | \\ \mathbf{u_1} & u_2 & \cdots & u_n & \cdots & u_m \\ | & | & & | & & | \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \sigma_n \\ 0 & \cdots & 0 & 0 \end{bmatrix} \begin{bmatrix} \text{---} & \mathbf{v_1} & \text{---} \\ \text{---} & v_2 & \text{---} \\ \vdots & \vdots & \vdots \\ \text{---} & v_n & \text{---} \end{bmatrix}$$
$$= \sigma_1 \mathbf{u_1} \mathbf{v_1}^\top$$

## Observación

Descomposición de  $A$  en matrices de rango 1.

$$A = \begin{bmatrix} | & | & & | & \cdots & | \\ \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_n & \cdots & \mathbf{u}_m \\ | & | & & | & & | \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \sigma_n \\ 0 & \cdots & 0 & 0 \end{bmatrix} \begin{bmatrix} \text{---} & \mathbf{v}_1 & \text{---} \\ \text{---} & \mathbf{v}_2 & \text{---} \\ \vdots & \vdots & \vdots \\ \text{---} & \mathbf{v}_n & \text{---} \end{bmatrix}$$
$$= \sigma_1 \mathbf{u}_1 \mathbf{v}_1^\top + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^\top$$

## Observación

Descomposición de  $A$  en matrices de rango 1.

$$A = \begin{bmatrix} | & | & & | & \cdots & | \\ \textcolor{blue}{u}_1 & \textcolor{violet}{u}_2 & \cdots & \textcolor{green}{u}_n & \cdots & u_m \\ | & | & & | & & | \end{bmatrix} \begin{bmatrix} \textcolor{blue}{\sigma}_1 & 0 & \cdots & 0 \\ 0 & \textcolor{violet}{\sigma}_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \textcolor{green}{\sigma}_n \\ 0 & \cdots & 0 & 0 \end{bmatrix} \begin{bmatrix} \text{---} & \textcolor{blue}{v}_1 & \text{---} \\ \text{---} & \textcolor{violet}{v}_2 & \text{---} \\ \vdots & \vdots & \vdots \\ \text{---} & \textcolor{green}{v}_n & \text{---} \end{bmatrix}$$
$$= \textcolor{blue}{\sigma}_1 \textcolor{blue}{u}_1 \textcolor{blue}{v}_1^\top + \textcolor{violet}{\sigma}_2 \textcolor{violet}{u}_2 \textcolor{violet}{v}_2^\top + \cdots + \textcolor{green}{\sigma}_n \textcolor{green}{u}_n \textcolor{green}{v}_n^\top$$



## Teorema de Eckart-Young



Considere la matriz  $A \in \mathbb{R}^{m \times n}$  y su descomposición en valores singulares  $A = U\Sigma V$ .  
Sea la matriz

$$A_k = \sigma_1 u_1 v_1^\top + \cdots + \sigma_k u_k v_k^\top$$

para  $k \leq \min\{m, n\}$ . Entonces,  $(\dim(\text{im}(A_k)) =) \text{rank}(A_k) = k$ . Además si  $B \in \mathbb{R}^{m \times n}$  es una matriz con  $\text{rank}(B) = k$ , entonces

$$\|A - A_k\| \leq \|A - B\|$$

# Ejemplo de compresión de imágenes



Figure: Imagen original




Figure: Sucesion de imagenes creadas con la SVD



**UC** | Chile

## **Tema 3: Análisis de Componentes principales**

## Problema



Dado un conjunto de datos  $X \in \mathbb{R}^{n \times N}$ , donde  $m$  es el número de atributos, buscamos reducir la dimensionalidad de estos conservando sus propiedades principales. Esto resulta ser relevante para muchas aplicaciones. Por ejemplo, donde queremos

- Pre-procesar los datos.
- Visualizar datos en menor dimensión.
- Extraer los features mas relevantes.

En resumen, queremos reducir la dimensión de los datos  $X$  a  $\tilde{X} \in \mathbb{R}^{n \times N}$ , donde  $n < m$  y  $\tilde{X}$  sea cercano a  $X$ .

# Introducción a PCA



El Análisis de Componentes Principales (PCA) es una técnica estadística que utiliza la SVD para reducir la dimensionalidad de los datos.

- ❑ Encuentra los ejes principales (componentes) en los cuales los datos tienen la mayor varianza.
- ❑ Proyecta los datos en estos nuevos ejes para obtener una representación de menor dimensión.

# Pasos Básicos de PCA



- 1 Centrar los datos.
- 2 Calcular la matriz de covarianza.
- 3 Calcular valores y vectores propios de la matriz de covarianza.
- 4 Seleccionar los componentes principales.
- 5 Proyectar los datos en el nuevo espacio.

# Pasos Básicos de PCA



- 1 Centrar los datos.
- 2 Calcular valores y vectores singulares de los datos centrados.
- 3 Seleccionar los componentes principales.
- 4 Proyectar los datos en el nuevo espacio.

# Visualización de PCA

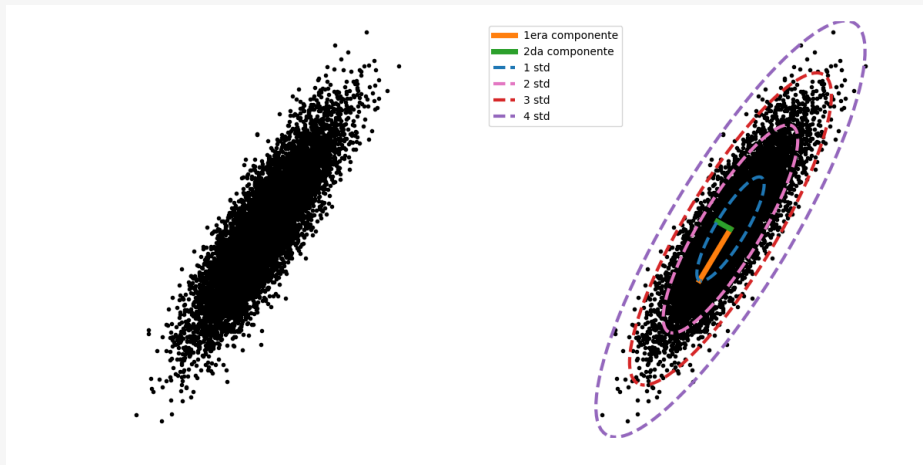


Figure: Distribucion de datos e interpretacion de PCA.



# Conclusiones



- Hemos introducido la SVD como una herramienta poderosa en álgebra lineal y análisis de datos.
- PCA es útil para reducir la dimensionalidad y preservar la información relevante en los datos.
- Profundizaremos en la aplicación computacional de estos en python en el tutorial.



**UC** | Chile